Gene-ius 발표 대본과 예상 질의응답

30 장 최종 슬라이드(v7) 기준, 한 사람이 이어서 읽는 대본입니다. 11 월 13 일 최종 제출(리더보드 0.48396)을 반영했습니다. 전체 약 18 분이고, **굵은 글씨**는 꼭 말할 숫자, [시연]은 화면 전환 지점입니다.

01 배경과 문제 (1~8 장)

1 장 · 표지 (40 초)

안녕하세요, 6 조 Gene-ius 입니다. 저희 팀은 최현영, 김정린, 나영철, 송승환 네 명입니다. 저희 주제는 암환자 유전체 데이터의 변이 정보로 암 아형을 분류하는 AI 모델입니다. 결과부터 말씀드리면 첫 제출 **0.2877** 에서 시작해 일주일 동안 **0.196** 을 올려, 최종 리더보드 **0.48396** 을 냈습니다. 어떻게 점수를 올렸는지, 그리고 이 모델로 만든 서비스 '원발 내비'까지 소개하겠습니다.

2 장 · 목차 (20 초)

발표는 배경과 문제, 방법, 핵심 발견, 결과와 교훈, 서비스 '원발 내비', 결론 순서로 진행하겠습니다.

3 장 · 원발 부위 불명암 (1 분)

먼저 이 문제가 왜 중요한지입니다. 암이 다른 장기로 전이된 것은 찾았는데, 처음 어디서 생겼는지 모르는 환자가 있습니다. 이를 원발 부위 불명암, CUP(컵)라고 합니다. 유럽종양내과학회 ESMO(에스모) 가이드라인에 따르면 전체 암의 3~5%가 여기에 해당합니다.

원발 부위를 모르면 어떤 표준 치료를 써야 할지 정하기 어렵습니다. 2023 년 Nature Medicine 의 OncoNPC(온코 엔피씨) 연구에서는, 유전자 패널로 예측한 원발 부위와 일치하는 치료를 받은 환자의 사망 위험이 **0.35 배**였습니다. 2024 년 Lancet(랜싯)의 CUPISCO(쿠피스코) 연구에서도 분자 맞춤 치료의 무진행 생존 기간이 **6.1 개월**로, 기존 항암 치료의 4.4 개월보다 길었습니다. 즉 유전자 변이로 암의 출발지를 맞힐 수 있다면, 실제 치료 선택으로 이어집니다.

4 장 · 문제 정의 (25 초)

저희가 받은 데이터는 환자 **6,201 명**, 유전자 열 **4,384 개**입니다. 표처럼 각 칸에는 변이가 없다는 뜻의 WT, 또는 R132H 같은 단백질 변화 표기가 들어 있습니다. 이 표기만 보고 **26 개** 암 아형 중 하나를 맞히는 것이 과제이고, 평가는 모든 아형을 같은 무게로 보는 Macro F1 입니다.

아래 네 숫자가 데이터의 특징인데, 먼저 표기 방식을 보고 6 장부터 하나씩 말씀드리겠습니다.

5 장 · HGVS 표기 (40 초)

칸에 적힌 표기는 HGVS 라는 변이 표기 국제 표준을 따릅니다. R132H 는 132 번째 아미노산 아르기닌이 히스티딘으로 바뀌었다는 뜻이고, 별표는 단백질이 거기서 끊긴다는 뜻, fs 는 읽는 틀이 밀린다는 뜻입니다.

그런데 같은 변이가 여러 모양으로 적혀 있었습니다. 2024 년 개정판도 1 글자와 3 글자 표기를 모두 허용하고 있고, R213X 의 X 는 2016 년 표준 이전에 종결 코돈을 적던 옛 표기입니다. 그래서 저희는 표기를 하나로 통일하는 파서를 만들었습니다. 이게 두 번째 핵심 발견입니다.

6 장 · 데이터 분포 (35 초)

이제 데이터가 어떻게 생겼는지 보겠습니다. 왼쪽 막대처럼 아형마다 환자 수 차이가 큽니다. 가장 많은 유방암 BRCA 는 **786 명**으로 12.7%, 가장 적은 림프종 DLBC 는 **38 명**, 0.6%로 약 **20.7 배** 차이입니다. Macro F1 은 아형마다 같은 비중이라, DLBC 를 놓쳐도 BRCA 를 놓친 만큼 점수가 깎입니다.

쏠림은 환자별 변이 수에도 있습니다. 변이가 있는 유전자 수는 중앙값 **14 개**인데 평균은 35.3 개, 가장 많은 환자는 **2,393 개**입니다. 이 차이가 뒤에서 말씀드릴 '변이 수 보정'의 출발점입니다.

7 장 · 유전자와 변이 빈도 (30 초)

유전자 열은 4,384 개지만 자주 변하는 것은 일부입니다. 왼쪽을 보시면 TP53 이 **1,770 명**, 전체의 28.5%로 압도적 1 위이고, PIK3CA 가 11%, 나머지는 10% 아래입니다.

오른쪽은 위치까지 붙인 개별 변이 순위로, IDH1 R132H **345 명**, BRAF V600E **321 명**이 두드러집니다. 아래 숫자처럼 변이 환자가 30 명 이하인 유전자가 1,790 개로 40%가 넘고, 전체 칸의 99.19%가 '변이 없음'입니다. 이렇게 희소한 데이터라서 안정적인 선형 모델 LR 을 기본으로 삼았습니다.

8 장 · 변이와 암종의 연결 (30 초)

그렇다면 특정 변이가 특정 암을 가리킬까요? 이 표에서 세 가지를 읽었습니다.

첫째, 짝 아형이 변이를 반씩 나눠 갖습니다. IDH1 R132H 는 GBMLGG **49.6%**, LGG 48.1%이고, VHL 도 KIPAN 47.2%, KIRC 46.3%입니다. 이 관찰이 '쌍 규칙'으로 이어졌습니다. 둘째, 한 변이가 한 아형의 대부분에 있습니다. LGG 의 72.5%가 IDH1 R132H, 대장암 COAD 의 71.7%가 APC 변이를 가져, 위치까지 읽는 핫스팟 피처가 중요했습니다. 셋째, 흔한 변이는 단서가 약합니다. TP53 은 거의 모든 아형에 있어 혼자서는 판단하기 어렵고, 이것이 서비스의 '판단 보류' 기능의 근거가 됐습니다.

이제 어떤 원칙으로 실험했는지 말씀드리겠습니다.

02 방법 (9~14 장)

9 장 · 실험 원칙 (45 초)

팀은 성능 개선과 서비스 기획으로 역할을 나눴고, 매일 회의록에 결론과 제출 기록, 결정 사항을 남겼습니다. 회의록은 GitHub 에 브랜치로 올리고 PR 리뷰를 거쳐 합쳤습니다.

오른쪽 실험 원칙은 전부 실패한 제출에서 나왔습니다. 여러 가지를 한꺼번에 바꾼 제출은 점수가 떨어져도 원인을 알 수 없어서 한 번에 하나만 바꾸기로 했습니다. 초기 계층 모델에서 전체 데이터로 기준을 정했다가 교차 검증이 부풀려져서, 모든 기준은 폴드 안에서 정합니다. 한 시드에서만 오른 변화는 다른 시드에서 떨어져 두 시드 모두 올라야 채택했고, 마지막 판단은 리더보드로 했습니다.

10 장 · 최종 모델 (55 초)

이 원칙으로 도착한 최종 모델은 다섯 단계입니다. 먼저 HGVS 파서로 변이를 읽어 유전자별 변이, 핫스팟, 변이 수 같은 피처를 만듭니다.

아래쪽 혼합 구조를 보시면, 기본 모델은 로지스틱 회귀 65%, LightGBM 20%, 암종별 변이 빈도 15%의 로그 점수를 합칩니다. v14 는 이 기본 모델 80%에, 기본 예측을 다시 보는 스태킹 LightGBM 20%를 합칩니다. v21 은 v14 80%에 아미노산 치환 LightGBM 20%를 합칩니다. 마지막 다섯 번째 단계에서 v21 80%에 '강화 코돈 후보' 20%를 섞고, 여기에 '치환 원형 LDA'를 5% 더한 뒤 최종 라벨에 쌍 규칙을 적용합니다. 두 후보는 13 장과 14 장에서 따로 말씀드리겠습니다.

교차 검증은 두 시드에서 **0.5791 과 0.5667**, 리더보드는 **0.48396** 입니다. 어휘, 스케일러, 열 선택 같은 기준은 모두 학습 데이터로만 만들고 제출 데이터에는 적용만 했습니다.

11 장 · 코드 계보 (40 초)

이 모델은 한 사람이 한 번에 만든 것이 아닙니다. 팀원 각자가 앞 버전 위에 한 층씩 쌓았습니다. 11 월 11 일에는 나영철 팀원의 v13 이 표기를 더 정리했고, 김정린 팀원의 final v6 가 HGVS 파서와 새 핫스팟 키를 넣었습니다. 11 월 12 일 최현영 팀원의 v21 이 변이 수 보정, 스태킹, 치환 패턴을 올려 **0.47615** 가 됐고, 이 v21 이 최종 모델의 대부분을 차지합니다.

12 장 · 11 월 12 일에 쌓은 것과 버린 것 (50 초)

11 월 12 일은 점수가 가장 크게 움직인 날입니다. final v6 위에 세 단계를 쌓았습니다. v9 에서 변이 수 보정과 암종별 변이 빈도를 더해 교차 검증 0.520, v14 에서 스태킹을 더해 0.535, v21 에서 아미노산 치환 모델을 더해 **0.560** 이 됐습니다. 세 단계 모두 두 시드에서 함께 올랐고, 리더보드는 final v6 의 0.4458 에서 0.4762 로 세 단계를 합쳐 0.030 올랐습니다.

오른쪽은 시도했지만 이날 쓰지 않은 것입니다. 치환 패턴을 더 다듬은 '서명 고도화'는 교차 검증이 0.58 까지 올랐지만 혼자 낸 리더보드는 오히려 낮아, 이날은 v21 을 유지했습니다. 이 후보는 다음 날 다시 쓰이는데, 그 이야기가 바로 다음 장입니다.

13 장 · 11 월 13 일: 버렸던 후보를 20%만 섞다 (45 초)

11 월 13 일에 마지막으로 점수를 올린 방법은 새 모델을 만든 것이 아니라, 전날 버렸던 후보를 조금 섞은 것입니다. 저희는 이 후보를 '강화 코돈 후보'라고 부르는데, 아미노산 치환을 네 가지 각도에서 다시 보는 모델입니다.

오른쪽 끝 카드처럼 이 후보는 혼자 냈을 때 리더보드 0.47596 으로 v21 보다 낮아 기각했었습니다. 그런데 v21 은 그대로 두고 이 후보를 20%만 섞자, 리더보드가 **0.47615 에서 0.48056** 으로 올랐습니다. 이유는 다른 각도로 본 모델은 틀리는 환자가 다르기 때문입니다. 혼자서는 약해도 조금 섞으면 v21 이 틀린 환자 일부를 바로잡아 줍니다.

아래 칸처럼 교차 검증 네 가지 설정에서 모두 올랐습니다. 층화 검증은 두 시드에서 **+0.005 와 +0.001**, 같은 변이 프로필을 한 폴드로 묶어 처음 보는 환자에 가깝게 만든 그룹 검증은 **+0.006 과 +0.008** 입니다.

14 장 · 11 월 13 일: 약한 모델을 5% 더 섞다 (45 초)

같은 날 같은 방법을 한 번 더 썼습니다. 이번에 섞은 것은 '치환 원형 LDA'입니다. 첫 번째 카드처럼 환자마다 R 에서 C 같은 아미노산 치환의 비율과, 그 치환을 만들 수 있는 염기 변화를 코돈표로 거꾸로 추정한 값을 특징 **444 개**로 만듭니다. 두 번째 카드의 LDA, 선형판별분석은 26 개 아형마다 평균 치환 패턴, 즉 '원형'을 하나씩 만들어 두고, 환자의 패턴이 어느 원형에 가장 가까운지 점수를 냅니다.

오른쪽 끝 카드처럼 이 모델은 혼자서는 교차 검증 **0.31** 로 약합니다. 그래서 기존 조합은 그대로 두고 **5%**만 더했습니다.

결과는 층화 교차 검증 두 시드에서 **+0.014 와 +0.012**, 리더보드는 **0.48056 에서 0.48396** 으로 올랐습니다.

03 핵심 발견 (15~18 장)

15 장 · 발견 1: 쌍 규칙 (50 초)

첫 번째 발견입니다.

KIPAN(키판)은 신장암 3 종을, GBMLGG 는 뇌종양 2 종을 합친 통합 코호트입니다. 그래서 학습 데이터에서 같은 변이 프로필이 두 코호트 라벨로 함께 관측됐고, 그런 묶음이 KIPAN·KIRC **272 개**, GBMLGG·LGG **173 개**였습니다. 변이가 똑같으니 모델은 두 라벨을 구분할 수 없습니다.

그래서 학습 폴드에서 한쪽 라벨로만 일치할 때 짝 라벨로 바꾸는 규칙을 만들었습니다. 코드에서는 먼저 변이 프로필 전체가 같은 학습 행을 찾고, 없으면 변이가 있는 유전자 조합이 같은 행을 찾습니다. 찾은 행의 라벨이 예컨대 KIRC 뿐이면 KIPAN 으로 답합니다. KIRC F1 이 **0.19 에서 0.76** 으로, 리더보드는 약 **0.10** 올랐습니다.

16 장 · 발견 2: HGVS 파서 (40 초)

두 번째는 앞에서 예고한 표기 문제입니다. 모델은 글자가 다르면 다른 변이로 읽습니다.

그래서 HGVS 규칙을 따르는 파서를 직접 만들었고, 학습 변이 **25 만 5 천여 개**를 판독 실패 0 개로 읽었습니다. 핫스팟 키도 유전자, 위치, 단백질 영향으로 만들어 표기가 달라도 같은 키가 되게 했습니다. 교차 검증은 그대로인데 리더보드만 **0.421 에서 0.446** 으로 올랐습니다. 교차 검증만 봤다면 놓쳤을 개선입니다.

17 장 · 발견 3: 고변이 대응 (40 초)

세 번째는 변이가 많은 환자에서 모델이 흔들린다는 것입니다. 앞에서 본 것처럼 변이 유전자 수는 중앙값 **14 개**인데 많은 환자는 **2,393 개**까지 있습니다.

변이가 많으면 7 장의 긴 유전자처럼 암과 무관한 우연한 변이, 이른바 승객 변이가 많이 섞여 모델이 속습니다. 그래서 변이가 많을수록 유전자 하나의 무게를 낮추는 변이 수 보정을 넣고, 스태킹으로 한 번 더 보정했습니다. 교차 검증은 v9 **0.520 에서 v14 0.535** 로 두 시드 모두 올랐습니다.

18 장 · 발견 4: 아미노산 치환 패턴 (50 초)

네 번째는 아미노산 치환 패턴을 피처로 쓴 것입니다. 배경부터 말씀드리면, 2013 년과 2020 년 Nature 의 돌연변이 서명 연구에 따르면 변이를 만드는 원인마다 남기는 흔적이 다릅니다. 자외선은 C 가 T 로 바뀌는 치환을 남겨 흑색종에 많고, 흡연은 C 가 A 로 바뀌는 치환을 남겨 폐암에 많습니다.

다만 저희 데이터에는 염기가 아니라 단백질 표기만 있습니다. 그래서 v21 이 실제로 계산하는 것은 환자마다 아미노산이 무엇에서 무엇으로 바뀌었는지의 비율, 예를 들어 R 에서 C, G 에서 V 로 바뀐 비율입니다. 이것으로 LightGBM 을 학습해 v14 에 20% 섞었습니다. 모델이 변이 원인을 직접 판정하는 것은 아니고, 환자 한 명 안에서만 계산하므로 정답이 새지 않습니다.

효과는 같은 폴드에서 v14 와 v21 을 비교했습니다. 쌍 규칙 조건을 같게 두고 교차 검증이 두 시드에서 **+0.025 와 +0.027** 올랐습니다.

04 결과와 교훈 (19~22 장)

19 장 · 점수 흐름 (20 초)

일주일을 한 그래프로 보면 이렇습니다. 첫 제출 **0.2877** 에서 **0.4840** 까지 올랐습니다. 가장 큰 계단은 11 월 9 일 쌍 규칙과 11 월 12 일 치환 패턴이고, 그 사이 꾸준한 상승은 표기 처리에서, 마지막 두 칸은 11 월 13 일 후보 혼합과 LDA 혼합에서 나왔습니다.

20 장 · 실패에서 배운 점 (30 초)

성공만 있었던 것은 아닙니다. 11 월 12 일 하루에만 18 가지를 시도해 6 가지를 채택했습니다.

가장 큰 교훈은 오른쪽입니다. 치환 패턴을 더 정교하게 다듬은 '서명 고도화'는 혼자 냈을 때 교차 검증이 **+0.020** 올랐지만 리더보드는 **−0.0002** 였습니다. 세밀하게 다듬을수록 학습 데이터 패턴에만 맞춰진 것입니다. 교차 검증은 방향은 알려 주지만 크기는 보장하지 않았습니다. 다만 이 후보를 버리지 않고 v21 에 20%만 섞자 리더보드가 **+0.0044** 올랐습니다.

21 장 · 한계 ① 변이가 적은 암끼리 헷갈린다 (40 초)

이제 한계를 말씀드리겠습니다. F1 이 낮은 아형은 대부분 변이가 적은 암입니다. 육종, 흉선암, 갈색세포종, 전립선암의 F1 이 시드 123 기준 **0.29 에서 0.38** 사이이고, 서로를 오답으로 고릅니다.

변이가 없는 환자는 정확도가 32%, 1~2 개인 환자는 47%인데, 100 개 이상인 환자는 80%입니다. 변이가 거의 없으면 모델이 볼 단서 자체가 없어, '변이가 적은 암' 묶음 안에서 서로 헷갈리는 것입니다.

22 장 · 한계 ②~⑤ (55 초)

나머지 한계는 네 가지입니다. 둘째, 치환 패턴은 변이가 적은 암에는 도움이 되지 않았습니다. 치환 비율은 변이가 많아야 패턴이 보여서, 자궁경부암은 크게 올랐지만 백혈병·갈색세포종·흉선암은 조금 내렸습니다.

셋째, 췌장암은 F1 이 두 시드 평균 **0.27 에서 0.34** 로 올랐지만 여전히 난소암과 반반입니다. 핵심 유전자인 KRAS(케이라스)와 SMAD4(스매드포) 열이 데이터에 없기 때문입니다.

넷째, 변이가 일부만 관측된 환자에 약합니다. 변이가 많은 환자의 변이를 일부만 남겨 검증하면 Macro F1 이 **0.56 에서 0.26** 으로 떨어졌습니다. 저희는 교차 검증과 리더보드 사이의 차이, 최종 모델 기준 0.095 가 여기서 왔다고 봅니다. 다섯째는 앞에서 말씀드린 대로, 교차 검증 개선이 리더보드로 그대로 넘어오지 않는 구간이 있었다는 점입니다.

05 서비스 '원발 내비' (23~26 장)

23 장 · 원발 내비 (35 초)

이런 한계를 알고 만든 서비스가 '원발 내비'입니다. 원발 부위 불명암 환자의 유전자 패널 결과를 넣으면 가능성 높은 원발 부위 후보를 안내합니다.

흐름은 네 단계입니다. 변이를 입력하면 후보 3 개와 확신 단계를 보여 주고, 확률을 가장 많이 올린 근거 변이를 함께 보여 주며, 근거가 부족하면 답하지 않습니다. 진단을 대신하는 도구가 아니라 보조 도구이고, 최종 판단은 의료진이 합니다.

24 장 · 실용화 (25 초)

주요 기능을 한 장에 정리했습니다. 모든 계산은 브라우저 안에서 이뤄져 환자 정보가 서버로 나가지 않고, 확신 단계마다 실제 적중률을 함께 보여 줍니다. 화면에 들어간 모델은 브라우저용 가벼운 로지스틱 회귀라, 상위 3 개 적중률은 **68%**입니다.

25 장 · 시연 (1 분 5 초)

직접 보여 드리겠습니다.

[시연 ① 예시 사례] 먼저 가상 환자 '뇌 병변' 사례입니다. 예시 버튼을 누르면 IDH1 R132H, ATRX, TP53 변이가 들어갑니다. 분석하면 저등급 신경교종이 **80.7%**로 1 순위이고 확신 단계는 '높음'입니다. 이 단계에서 실제로 맞힌 비율은 76%로, 확률과 함께 보여 줍니다.

[시연 ② TP53 단독] 다음은 TP53 변이 하나만 넣어 보겠습니다. 개발 초기에는 이렇게 넣으면 백혈병이 1 순위로 나왔습니다. 8 장에서 본 것처럼 TP53 은 거의 모든 암에 나타나 혼자서는 원발 부위를 가리키지 못합니다. 그래서 지금은 보시는 것처럼 '판단 보류'를 띄웁니다. 모를 때는 모른다고 말하는 화면이 저희가 가장 신경 쓴 부분입니다.

[시연 ③ 일괄 분석] 마지막으로 환자 여러 명의 파일을 넣으면 한 번에 분석합니다. 학습 데이터 6,201 명을 약 2 초에 처리합니다.

26 장 · 시연 요약 (15 초)

방금 보신 두 장면을 정리하면, 변이가 충분하면 확신 있게 답하고, 근거가 부족하면 틀린 답을 내기보다 '모른다'고 말합니다. 신경교종 계열로 묶으면 확률은 98.5%입니다. (시연이 안 될 때는 이 장으로 시연을 대신하세요.)

06 결론 (27~30 장)

27 장 · 결론 (35 초)

정리하겠습니다. 저희가 일주일간 배운 것은 데이터의 구조를 이해한 만큼 점수가 올랐다는 것입니다. 같은 변이 프로필을 찾은 쌍 규칙, 같은 변이를 같게 읽은 표기 정규화, 변이 수에 따른 보정, 아미노산 치환 패턴까지, 네 가지 모두 데이터를 들여다봐서 찾았습니다.

앞으로는 세 단계를 생각하고 있습니다. 공개된 유전자 패널 데이터로 외부 검증을 하고, 전이 종양에서 성능을 확인한 뒤, 병원 데이터로 후향 연구를 하는 것입니다.

28~29 장 · Q&A, 마무리 (20 초)

지금까지 6 조 Gene-ius 의 발표였습니다. 최종 리더보드 **0.48396**, 일주일 동안 데이터를 들여다본 기록이었습니다. 들어 주셔서 감사합니다. 궁금하신 점을 질문해 주시면 차례로 답변드리겠습니다.

30 장 · 참고 자료

읽지 않고 띄워만 둡니다. 근거를 묻는 질문이 나오면 이 장을 보여 주세요.

예상 질의응답

가장 나올 가능성이 높은 것은 쌍 규칙의 규정 여부(Q1), 교차 검증·리더보드 차이(Q9), 그리고 이번에 추가된 후보 혼합이 리더보드에 맞춘 것 아니냐는 질문(Q14)입니다. 세 답은 외워 두세요.

규정과 누수

Q1. 쌍 규칙은 정답을 베끼는 것 아닌가요?

제출 데이터의 한 행을 학습 데이터와만 비교합니다. 제출 행끼리 비교하거나 제출 데이터 통계를 쓰지 않습니다. 근거는 KIPAN·GBMLGG 가 통합 코호트라는 TCGA 의 구조입니다. 이후 개선은 쌍 규칙 없이도 오르는지 따로 확인했는데, 예를 들어 스태킹은 쌍 규칙 없이도 +0.0198 이었습니다. 환자 ID 를 확인한 것이 아니라 "같은 변이 프로필이 두 라벨에서 관측됐다"는 사실에 기댄 규칙이라고 말하세요.

Q2. 제출 데이터를 보고 전처리를 맞춘 것 아닌가요?

모든 기준(어휘, 스케일러, 열 선택, 희귀 유형)은 학습 데이터로만 정했고, 제출 데이터에는 행 단위로 적용만 했습니다. 표기 통일은 HGVS 국제 표준의 표기 변형을 하나로 맞춘 것이고, 제출 데이터 분포를 학습에 넣지 않았습니다.

Q3. 교차 검증에 누수는 없나요?

선택·보정 단계까지 폴드 안에서 했고, 스태킹도 내부 4 겹 예측만 입력으로 썼습니다. 같은 변이 프로필을 한 폴드로 묶은 그룹 검증에서도 v14 0.4725 → v21 0.5082 로 개선이 유지됐고, 마지막 후보 혼합도 그룹 검증 두 시드에서 +0.006, +0.008 올랐습니다. 초기 계층 모델에서 누수를 발견해 기각한 경험이 이 원칙의 계기였습니다.

Q4. 생성형 AI 는 어떻게 썼나요?

운영진 답변(11/6)에 따라 활용했습니다. 코드 작성과 검토에 쓰고, 서로 다른 AI 의 결과를 교차 확인했습니다. 채택 여부는 항상 검증 점수와 리더보드로 팀이 판단했습니다.

방법

Q5. 왜 딥러닝이 아니라 로지스틱 회귀인가요?

칸의 99.19%가 비어 있는 희소 데이터에 환자는 6,201 명뿐입니다(7 장). 이런 조건에서는 규제된 선형 모델이 안정적입니다. CNN 이미지화는 정확도 4% 수준이라 중단했고, SVM·나이브 베이즈도 효과가 없었습니다. 비선형 조합은 LightGBM 과 스태킹으로 보완했습니다.

Q6. 단백질 표기만 있는데 변이 원인을 어떻게 알 수 있나요?

알 수 없고, 판정하지도 않습니다. 염기 수준 서명(C>T 등)을 직접 보지 못하므로, 환자별 아미노산 치환 쌍의 비율을 피처로 썼고, 서명 연구는 이 피처를 떠올린 배경입니다. 효과는 같은 폴드에서 v14 → v21 교차 검증 +0.025·+0.027 로 확인했습니다. 리더보드 +0.030 은 final v6 부터의 누적 수치라 치환 모델만의 효과로 말하지 마세요.

Q7. 클래스 불균형은 어떻게 다뤘나요?

클래스 가중치(balanced)와 층화 교차 검증만 썼습니다. 분석해 보니 아형 크기와 F1 의 순위 상관이 −0.003 이었습니다. ACC 는 72 명인데 F1 0.87, KIPAN 은 515 명인데 0.22 였습니다. 불균형보다 구분 정보의 유무가 핵심이라 추가 보정은 하지 않았습니다.

Q8. 외부 데이터는 왜 쓰지 않았나요?

운영진이 논문 지식과 외부 데이터 사용을 허용했고, 치환 패턴 피처는 논문 지식(Alexandrov 외)에서 출발했습니다. 외부 변이 데이터를 직접 학습에 넣는 것은 기간 안에 검증할 여유가 없어 향후 과제로 남겼습니다.

결과 해석

Q9. 교차 검증 0.579 와 리더보드 0.484 는 왜 이렇게 다른가요?

학습 데이터로 만든 '부분 관측' 검증이 근거입니다. 변이가 많은 환자의 변이를 일부만 남겨 검증하면 Macro F1 이 0.56 에서 0.26 으로 떨어졌습니다(22 장 ④). 표기를 통일하자 교차 검증은 그대로인데 리더보드만 0.421 에서 0.446 으로 오른 것도 같은 이유로 봅니다. 즉 차이는 모델보다 입력의 차이에서 왔습니다. 제출 데이터의 분포는 보지 않았기 때문에 '추정'이라고 분명히 말하세요.

Q10. 교차 검증이 더 높은 모델(0.58)을 왜 단독으로 쓰지 않았나요?

단독 리더보드가 0.47596 으로 v21(0.47615)보다 낮았습니다. 세밀하게 다듬을수록 학습 데이터 패턴에 맞춰졌기 때문입니다. 대신 v21 은 그대로 두고 이 후보를 20%만 섞자 리더보드가 0.48056 으로 올랐고, 여기에 치환 원형 LDA 5%를 더한 것이 최종 모델입니다. 단독으로는 버리고, 보조 의견으로만 쓴 것입니다.

Q11. 점수가 낮은 아형은 어떻게 개선할 수 있나요?

두 가지가 다릅니다. 육종·흉선암·갈색세포종·전립선암(시드 123 F1 0.29~0.38)은 변이 자체가 적어 단서가 부족합니다(21 장). 췌장암은 핵심 유전자 KRAS·SMAD4 열이 데이터에 없습니다(22 장). 둘 다 모델보다 입력의 한계라, 실제 서비스에서는 이 유전자를 포함한 패널 결과가 필요합니다. 유전자와 무관한 치환 패턴으로 췌장암이 두 시드 평균 0.27 에서 0.34 로 오른 것이 한 방향입니다.

Q12. SKCM 예측이 많았는데 왜 줄이지 않았나요?

줄이는 버전(v7)을 제출했더니 리더보드가 0.0032 떨어졌습니다. 흑색종은 변이가 많은 암이라, 예측이 많아 보여도 실제로 맞는 예측일 수 있습니다. 쏠림이 보인다고 모두 오류는 아니었고, 이후에는 근거가 확인된 변화만 반영했습니다.

Q13. RYR2·SYNE1·PCLO 는 왜 변이 상위에 있나요?

유전자가 길어서입니다. 단백질 길이로 TP53 은 약 390, RYR2 는 약 5,000, SYNE1 은 약 8,800 아미노산이라, 암과 무관하게 우연한 변이(승객 변이)가 많이 쌓입니다. Lawrence 외(Nature 2013)도 긴 유전자가 변이 빈도만으로는 암 유전자처럼 보이는 문제를 지적했습니다. 그래서 변이 수 보정으로 변이가 많은 환자에서 유전자 하나의 무게를 낮췄습니다.

Q14. 버렸던 모델을 섞었더니 올랐다는 건, 리더보드에 맞춘 것 아닌가요?

20% 혼합의 효과는 리더보드 전에 교차 검증 네 설정(층화 2 개, 그룹 2 개)에서 모두 확인했습니다(13 장). 리더보드는 그 결과를 확인하는 마지막 단계로만 썼습니다. 다만 리더보드 상승 +0.0044 는 작은 폭이므로, 비공개 평가에서도 같은 크기로 유지된다고 단정하지 마세요.

Q15. 20%라는데, 실제로 새로 들어간 정보는 얼마나 되나요?

후보 안에도 v14 가 들어 있어서, 로그 점수 비중으로 풀어 보면 v14 약 73%, 아미노산 치환 모델 15%, 코돈·서명·혼합기 몫은 약 7%, 마지막에 더한 치환 원형 LDA 가 5%입니다. 그래서 v21 의 예측 대부분은 그대로이고, 아형 간 점수 차가 작은 환자에서 답이 바뀝니다.

Q16. 왜 그룹 검증에서 더 크게 올랐나요?

그룹 검증은 학습 데이터에 같은 변이 프로필이 없는 환자로만 평가해, 처음 보는 환자를 맞혀야 하는 리더보드와 성격이 비슷하다고 봅니다. 여기서 +0.006·+0.008 로 층화 검증(+0.005·+0.001)보다 컸습니다. 치환·코돈 패턴은 특정 유전자 칸에 덜 의존해 처음 보는 변이 조합에도 쓸 수 있기 때문으로 해석하지만, 추정이라고 말하세요.

Q17. 코돈 역추정은 무엇이고, 정확한가요?

R→C 같은 아미노산 변화를 만들 수 있는 DNA 한 글자 변화를 유전 암호표에서 거꾸로 찾아, 가능한 경우를 나눠 셉니다. 예를 들어 한 아미노산 변화가 두 가지 염기 치환으로 가능하면 각각 절반씩 셉니다. 실제 염기를 본 것이 아니라 가능성의 분포라서, 변이 원인을 판정하는 것은 아닙니다.

Q18. 치환 원형 LDA 는 무엇이고, 왜 5%만 섞었나요?

아형마다 평균 치환 패턴(원형)을 만들어 두고, 환자의 치환 패턴이 어느 아형과 가장 닮았는지 점수를 매기는 모델입니다. 특징 444 개에 비해 DLBC 처럼 38 명뿐인 아형이 있어 공분산 추정을 크게 단순화(축소 0.65)했고, 26 개 아형의 사전확률을 같게 두었습니다. 단독 교차 검증은 0.31 로 약해서 5%만 더했고, 그래도 아형 사이 점수 폭이 커서 1·2 위가 근소한 환자의 답을 바꿉니다. 효과는 층화 교차 검증 두 시드 +0.014·+0.012 로 먼저 확인했습니다. 그룹 검증은 하지 않았으니, 묻는다면 솔직하게 답하세요.

서비스와 비즈니스

Q19. 원발 내비에는 최종 모델이 들어 있나요?

아니요. 브라우저에서 돌아가는 가벼운 로지스틱 회귀(Macro F1 0.419, 상위 3 개 적중 68%)입니다. 환자 정보를 서버로 보내지 않는 구조를 우선했고, 최종 모델 이식은 다음 단계입니다.

Q20. 실제 환자에게 쓸 수 있나요?

아직은 연구용입니다. 학습 데이터는 대부분 원발 종양이라 전이 종양에서의 성능을 따로 검증해야 하고, 실제 사용에는 다기관 검증과 인허가가 필요합니다. 그래서 후보 3 개와 확신 단계를 보여 주고, 근거가 약하면 판단을 보류하며, 최종 판단은 의료진이 내립니다.

Q21. 같은 목적의 상용 검사와 무엇이 다른가요?

새 검사를 하지 않고, 이미 받은 유전자 패널 결과만으로 후보를 제시합니다. 근거 변이와 판단 보류를 보여 주는 설명 가능성, 브라우저 안에서만 계산하는 개인정보 보호가 차별점입니다. 상용 검사와의 직접 성능 비교는 하지 못했다고 솔직하게 답하세요.

답하기 어려운 질문을 받으면

- 모르는 숫자는 추측하지 말고 "확인하지 못했다"고 답합니다.
- 한계를 짚는 질문은 인정하고, 그래서 무엇을 했는지(검증 원칙, 판단 보류)로 이어 갑니다.

참고 논문·자료

대본과 답변에서 인용한 자료입니다. "근거가 무엇인가요"가 나오면 이 목록을 쓰세요.

분야	자료	어디에 썼나	슬라이드
변이 표기	HGVS 변이 표기 규칙 (den Dunnen 외 2016, Hart 외 2024)	HGVS 파서	5 장, 16 장
쌍 규칙	TCGA GDAC Firehose (KIPAN = KICH+KIRC+KIRP, GBMLGG)	통합 코호트 구조	15 장
쌍 규칙	Ricketts 외, Cell Reports 2018 · Ceccarelli 외, Cell 2016	같은 변이 프로필이 두 코호트에 있는 근거	15 장
돌연변이 서명	Alexandrov 외, Nature 2013·2020	치환 패턴 피처의 배경	18 장
돌연변이 서명	TumorTracer (Marquard 외, BMC Medical Genomics 2015)	염기 치환 스펙트럼으로 원발 부위 분류	18 장
돌연변이 서명	Jiao 외, Nature Communications 2020	변이 패턴만으로 암종 분류, 후보 3 개 표시	18 장, 23 장
승객 변이	Lawrence 외, Nature 2013	긴 유전자의 변이 빈도 문제 (Q13)	7 장
서비스 기획	ESMO 원발 부위 불	전체 암의 3~5%	3 장, 24 장

	명암 가이드라인 2023		
서비스 기획	OncoNPC (Moon 외, Nature Medicine 2023)	원발 부위 예측, 사망 위험비 0.35	3 장, 24 장
서비스 기획	CUPISCO (Lancet 2024)	무진행 생존 6.1 대 4.4 개월	3 장, 24 장
서비스 기획	Hoadley 외, Cell 2018	분자 분류의 주축은 기원 조직	24 장